

08-Tarea

1. ENIGH

Para este ejercicio usaremos los datos de la ENIGH 2014. En particular las variables alimentos, vestido, vivienda, salud, comunica, educacion y esparci (esparcimiento) que indican el gasto trimestral en cada una de las categorías.

1. Calcula los deciles de ingreso usando la variable de ingreso corriente (ing\_cor).

Debes tomar en cuenta el diseño de la muestra, puedes usar la función `survey_quantile()` del paquete `srvyr` o `svyquantile()` del paquete `survey`. Reporta las estimaciones y sus errores estándar usando el bootstrap de Rao y Wu.

```
library(readr)
library(dplyr)

concentrado_hogar <- read_csv("concentradohogar.csv")

hogar <- concentrado_hogar %>%
  select(folioviv, foliohog, est_dis, upm, factor_hog, ing_cor, alimentos,
         vestido, vivienda, salud, transporte, comunica, educacion, esparci)

glimpse(hogar)
```

```
## Rows: 19,479
## Columns: 14
## $ folioviv    <chr> "0100008302", "0100008303", "0100008304", "0100008305", ...
## $ foliohog    <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 3, 1, ...
## $ est_dis      <chr> "005", "005", "005", "005", "005", "005", "005", "005", ...
## $ upm         <chr> "00670", "00670", "00670", "00670", "00600", "00600", "00600", ...
## $ factor_hog <dbl> 694, 694, 694, 694, 660, 660, 660, 660, 660, 583, 583, 583, ...
## $ ing_cor      <dbl> 39786.79, 19523.90, 99257.66, 87883.68, 84427.04, 232013. ...
## $ alimentos    <dbl> 11172.63, 1941.38, 16759.08, 8678.43, 12873.09, 18530.30, ...
## $ vestido       <dbl> 0.00, 0.00, 489.12, 293.47, 0.00, 4519.53, 0.00, 0.00, 0.00, ...
## $ vivienda     <dbl> 2199.32, 0.00, 2989.43, 1100.00, 3062.50, 1580.00, 5090. ...
## $ salud          <dbl> 1401.83, 117.38, 1242.37, 420.63, 0.00, 33534.75, 2974.8, ...
## $ transporte    <dbl> 5490.71, 0.00, 5829.25, 1440.00, 7006.44, 16669.55, 7896. ...
## $ comunica      <dbl> 1110.00, 0.00, 2540.32, 1440.00, 1200.00, 4703.22, 2670. ...
## $ educacion     <dbl> 0.00, 0.00, 0.00, 3019.35, 0.00, 22285.15, 0.00, 24262.1, ...
## $ esparci       <dbl> 900.00, 0.00, 0.00, 0.00, 1050.00, 7066.23, 12182.60, 0.00, ...
```

```
library(srvyr)
library(survey)

enigh design <- hogar %>%
```

```

  as_survey_design(ids = upm, weights = factor_hog, strata = est_dis)

set.seed(2020)

enigh_boot <- enigh_design %>%
  as_survey_rep(type = "subbootstrap", replicates = 500)

enigh_boot %>%
  srvyr::summarise(mean_ingcor = survey_mean(ing_cor))

## # A tibble: 1 x 2
##   mean_ingcor mean_ingcor_se
##       <dbl>         <dbl>
## 1     39719.        973.

qq <- svyquantile(~ing_cor, enigh_boot, quantiles = seq(0.1, 1, 0.1), interval.type = "quantile")
qq

## Statistic:
##      ing_cor
## q0.1 10622.27
## q0.2 14775.08
## q0.3 18597.46
## q0.4 22682.01
## q0.5 27185.82
## q0.6 32725.96
## q0.7 40057.31
## q0.8 51990.48
## q0.9 76284.93
## q1   4150377.02
## SE:
##      ing_cor
## q0.1 149.6292
## q0.2 180.8199
## q0.3 201.8311
## q0.4 222.9581
## q0.5 236.9197
## q0.6 331.2135
## q0.7 475.4123
## q0.8 787.6235
## q0.9 1388.5234
## q1   1342955.8688

```

2. Crea una nueva variable que indique el decil de ingreso para cada hogar. Tips: 1) una función que puede resultar útil es `cut2()` (de `Hmisc`),
- 2) si usas el paquete `srvyr` puedes usar `mutate()` sobre el objeto `survey` con pesos de replicaciones bootstrap.

```

library(Hmisc)

## Loading required package: lattice

```

```

## Loading required package: Formula

## Loading required package: ggplot2

##
## Attaching package: 'Hmisc'

## The following object is masked from 'package:survey':
##      deff

## The following object is masked from 'package:srvyr':
##      summarize

## The following objects are masked from 'package:dplyr':
##      src, summarize

## The following objects are masked from 'package:base':
##      format.pval, units

```

```

hogar$decil<-as.character(cut2(hogar$ing_cor,qq))
hogar

```

```

## # A tibble: 19,479 x 15
##   folioviv foliohog est_dis upm   factor_hog ing_cor alimentos vestido vivienda
##   <chr>     <dbl> <chr>   <chr>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
## 1 0100008~     1 005  00670     694  39787.  11173.     0  2199.
## 2 0100008~     1 005  00670     694  19524.  1941.     0     0
## 3 0100008~     1 005  00670     694  99258.  16759.    489.  2989.
## 4 0100008~     1 005  00670     694  87884.  8678.    293.  1100
## 5 0100010~     1 005  00600     660  84427.  12873.     0  3062.
## 6 0100010~     1 005  00600     660  232014. 18530.    4520.  1580
## 7 0100010~     1 005  00600     660  90941.  10819.     0  5090.
## 8 0100010~     1 005  00600     660  70309.  12491.     0  1755
## 9 0100010~     1 005  00600     660  92508.  6853.     0  15456.
## 10 0100018~    1 004  00570     583  80865.  12876.    84.1  2053
## # ... with 19,469 more rows, and 6 more variables: salud <dbl>,
## #   transporte <dbl>, comunica <dbl>, educacion <dbl>, esparci <dbl>,
## #   decil <chr>

```

3. Estima para cada decil, el porcentaje del gasto en cada categoría (), reporta el error estándar de las estimaciones, usa el bootstrap de Rao y Wu.

Tip: - 1) agrega una variable que indica para cada hogar el porcentaje de gasto en cada categoría,

- 2) si usas srvyr puedes usar la función `group_by()` para estimar la media del porcentaje de gasto por decil.

```

fun_zero <- function(x){
  if(x==0){
    return(.01)
  }
  else{
    return(x)
  }
}

den <- sapply((hogar$alimentos +
               hogar$vestido +
               hogar$vivienda +
               hogar$salud +
               hogar$transporte +
               hogar$comunica +
               hogar$educacion +
               hogar$esparci),
               fun_zero)

hogar$p_alim <- hogar$alimentos/den
hogar$p_vestido <- hogar$vestido/den
hogar$p_vivienda <- hogar$vivienda/den
hogar$p_salud <- hogar$salud/den
hogar$p_transporte <- hogar$transporte/den
hogar$p_comunica <- hogar$comunica/den
hogar$p_educacion <- hogar$educacion/den
hogar$p_esparci <- hogar$esparci/den

enigh_design2 <- hogar %>%
  as_survey_design(ids = upm, weights = factor_hog, strata = est_dis)

enigh_boot2 <- enigh_design2 %>%
  as_survey_rep(type = "subbootstrap", replicates = 500)

err <- data.frame(enigh_boot2 %>%
  srvyr::group_by(decil) %>%
  srvyr::summarise(mean_palim = survey_mean(p_alim),
                    mean_pvestido = survey_mean(p_vestido),
                    mean_pvivienda = survey_mean(p_vivienda),
                    mean_psalud = survey_mean(p_salud),
                    mean_ptransporte = survey_mean(p_transporte),
                    mean_pcomunica = survey_mean(p_comunica),
                    mean_peducacion = survey_mean(p_educacion),
                    mean_pesparci = survey_mean(p_esparci)))
err

##           decil mean_palim mean_palim_se mean_pvestido mean_pvestido_se
## 1      [     0, 10622)  0.6294435  0.006179444   0.02736907  0.001512451
## 2      [ 10622, 14775)  0.5714863  0.005307653   0.02838772  0.001487148
## 3      [ 14775, 18597)  0.5397263  0.004739619   0.02656811  0.001196838
## 4      [ 18597, 22682)  0.5241734  0.004553359   0.02746975  0.001133882
## 5      [ 22682, 27186)  0.4963811  0.004725181   0.02771933  0.001052654
## 6      [ 27186, 32726)  0.4774084  0.004633190   0.03010250  0.001690471

```

```

## 7 [ 32726, 40057) 0.4531834 0.004553305 0.03174477 0.001237088
## 8 [ 40057, 51990) 0.4307530 0.004128175 0.03465659 0.001226922
## 9 [ 51990, 76285) 0.3976248 0.004519442 0.03584568 0.001285889
## 10 [ 76285,4150377] 0.3235232 0.004963262 0.04236249 0.001626010
##   mean_pvivienda mean_pvivienda_se mean_psalud mean_psalud_se mean_ptransporte
## 1      0.1303336    0.004492607  0.02595083  0.002099225  0.1141557
## 2      0.1361030    0.003748815  0.02888787  0.002448672  0.1362703
## 3      0.1350544    0.003089434  0.02196807  0.001491518  0.1608099
## 4      0.1251411    0.002956287  0.02208445  0.001585537  0.1705709
## 5      0.1265108    0.003079101  0.01927620  0.001386682  0.1940208
## 6      0.1181212    0.002808902  0.02016949  0.001509973  0.2072038
## 7      0.1194003    0.003125958  0.02006211  0.001266755  0.2175729
## 8      0.1121987    0.003047056  0.02301865  0.001771198  0.2250942
## 9      0.1069972    0.003153454  0.02551481  0.001878510  0.2430384
## 10     0.1049304    0.004560591  0.03788884  0.002856598  0.2496626
##   mean_ptransporte_se mean_pcomunica mean_pcomunica_se mean_peducacion
## 1      0.003823567  0.02038837   0.001225578  0.03526563
## 2      0.003946988  0.02873609   0.001137577  0.05406708
## 3      0.003786735  0.03508495   0.001326424  0.06293573
## 4      0.003212897  0.03812413   0.001226898  0.07481153
## 5      0.003487618  0.04200418   0.001267451  0.07375984
## 6      0.003564719  0.04871028   0.001343528  0.07380523
## 7      0.004077495  0.05337407   0.001346526  0.08019964
## 8      0.003017469  0.05613178   0.001304853  0.08622370
## 9      0.003536906  0.06117834   0.001160116  0.09402181
## 10     0.004975099  0.06678864   0.001566101  0.12187710
##   mean_peducacion_se mean_pesparci mean_pesparci_se
## 1      0.002126691  0.009966443  0.0009167362
## 2      0.003263709  0.012302919  0.0007619998
## 3      0.003162207  0.016388612  0.0010599630
## 4      0.003610525  0.017113520  0.0010756223
## 5      0.003339691  0.018185868  0.0008796838
## 6      0.003450374  0.020952883  0.0011905733
## 7      0.003441691  0.024114423  0.0010537542
## 8      0.003607545  0.030272428  0.0019951849
## 9      0.004031063  0.035778979  0.0014494231
## 10     0.006658080  0.052622285  0.0022912849

```

4. Realiza una gráfica con las estimaciones del paso 3.

```

library(ggplot2)
library(patchwork)
x_ <- c(0.1,0.2,0.3,0.4,0.5,0.6,0.7,0.8,0.9,1)
err$decil_r <- x_

df <- err %>% select("decil_r", "mean_palim", "mean_palim_se")

g_alim <- ggplot(err %>% select("decil_r", "mean_palim", "mean_palim_se"),
                   aes(x_,
                       mean_palim*100,
                       ymin = mean_palim*100 - mean_palim_se*100,
                       ymax = mean_palim*100 + mean_palim_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +

```

```

  xlab("decil") +
  ylab("alimentos")

## Warning: Ignoring unknown parameters: width

g_vestido <- ggplot(err %>% select("decil_r", "mean_pvestido", "mean_pvestido_se"),
  aes(x_,
      mean_pvestido*100,
      ymin = mean_pvestido*100 - mean_pvestido_se*100,
      ymax = mean_pvestido*100 + mean_pvestido_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("vestido")

## Warning: Ignoring unknown parameters: width

g_vivienda <- ggplot(err %>% select("decil_r", "mean_pvivienda", "mean_pvivienda_se"),
  aes(x_,
      mean_pvivienda*100,
      ymin = mean_pvivienda*100 - mean_pvivienda_se*100,
      ymax = mean_pvivienda*100 + mean_pvivienda_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("vivienda")

## Warning: Ignoring unknown parameters: width

g_salud <- ggplot(err %>% select("decil_r", "mean_psalud", "mean_psalud_se"),
  aes(x_,
      mean_psalud*100,
      ymin = mean_psalud*100 - mean_psalud_se*100,
      ymax = mean_psalud*100 + mean_psalud_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("salud")

## Warning: Ignoring unknown parameters: width

g_transporte <- ggplot(err %>% select("decil_r", "mean_ptransporte", "mean_ptransporte_se"),
  aes(x_,
      mean_ptransporte*100,
      ymin = mean_ptransporte*100 - mean_ptransporte_se*100,
      ymax = mean_ptransporte*100 + mean_ptransporte_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("transporte")

## Warning: Ignoring unknown parameters: width

```

```

g_educa <- ggplot(err %>% select("decil_r", "mean_peducacion", "mean_peducacion_se"),
  aes(x_,
      mean_peducacion*100,
      ymin = mean_peducacion*100 - mean_peducacion_se*100,
      ymax = mean_peducacion*100 + mean_peducacion_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("educacion")

```

## Warning: Ignoring unknown parameters: width

```

g_comunica <- ggplot(err %>% select("decil_r", "mean_pcomunica", "mean_pcomunica_se"),
  aes(x_,
      mean_pcomunica*100,
      ymin = mean_pcomunica*100 - mean_pcomunica_se*100,
      ymax = mean_pcomunica*100 + mean_pcomunica_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("comunica")

```

## Warning: Ignoring unknown parameters: width

```

g_esparci <- ggplot(err %>% select("decil_r", "mean_pesparci", "mean_pesparci_se"),
  aes(x_,
      mean_pesparci*100,
      ymin = mean_pesparci*100 - mean_pesparci_se*100,
      ymax = mean_pesparci*100 + mean_pesparci_se*100)) +
  geom_pointrange(width = 0.2, size = 0.3, color="black", fill="red", shape=21) +
  xlab("decil") +
  ylab("esparci")

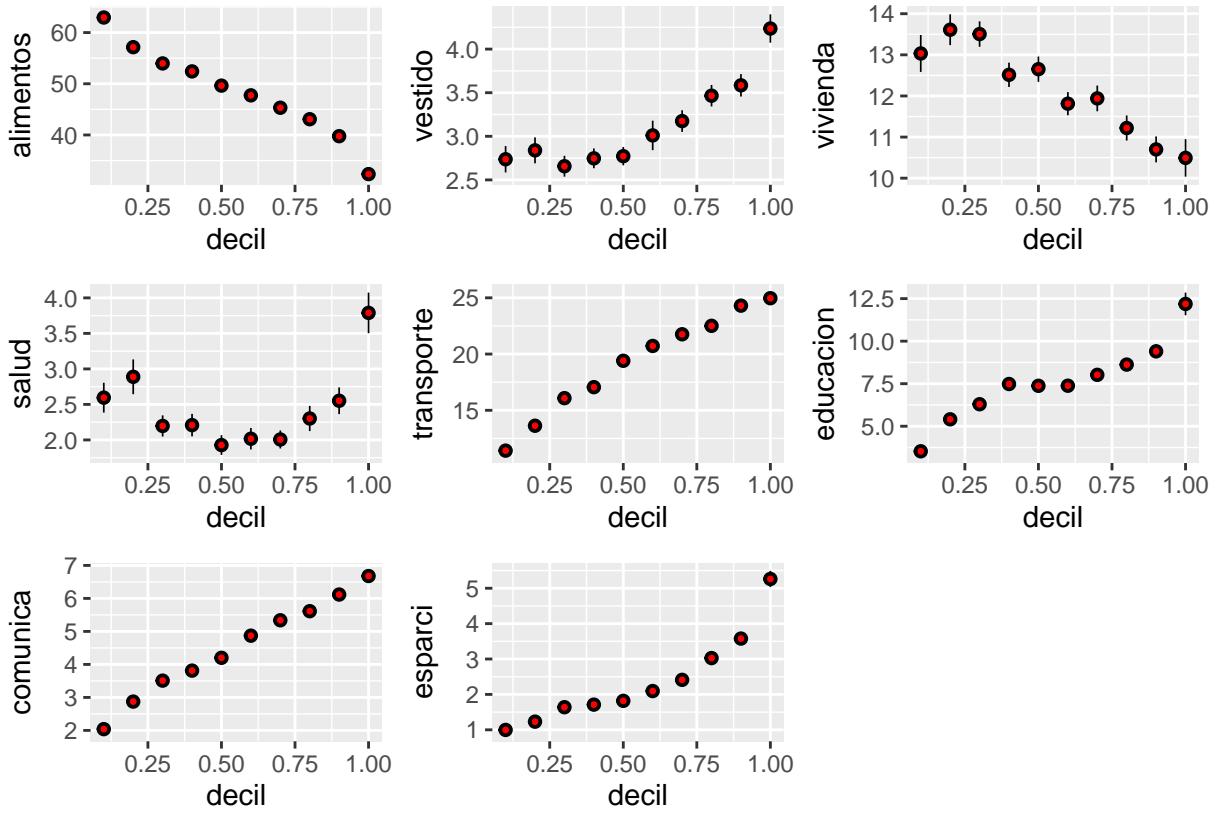
```

## Warning: Ignoring unknown parameters: width

```

g_alim + g_vestido + g_vivienda + g_salud + g_transporte + g_educa + g_comunica + g_esparci

```



## 2. Componentes Principales

Los datos *marks* (Mardia, Kent y Bibby, 1979) contienen los puntajes de 88 estudiantes en 5 pruebas: mecánica, vectores, álgebra, análisis y estadística. Cada renglón corresponde a la calificación de un estudiante en cada prueba. Para este ejercicio no es necesario que conozcas componentes principales pues puedes implementar el bootstrap siguiendo el código propuesto y discutiremos los detalles del análisis en la próxima clase.

```
data(marks, package = "ggm")
glimpse(marks)
```

```
## Rows: 88
## Columns: 5
## $ mechanics <dbl> 77, 63, 75, 55, 63, 53, 51, 59, 62, 64, 52, 55, 50, 65, ...
## $ vectors    <dbl> 82, 78, 73, 72, 63, 61, 67, 70, 60, 72, 64, 67, 50, 63, ...
## $ algebra    <dbl> 67, 80, 71, 63, 65, 72, 65, 68, 58, 60, 60, 59, 64, 58, ...
## $ analysis   <dbl> 67, 70, 66, 70, 70, 64, 65, 62, 62, 62, 63, 62, 55, 56, ...
## $ statistics <dbl> 81, 81, 81, 68, 63, 73, 68, 56, 70, 45, 54, 44, 63, 37, ...
```

Un análisis de componentes principales proseguiría como sigue:

```
pc_marks <- princomp(marks)
summary(pc_marks)
```

```

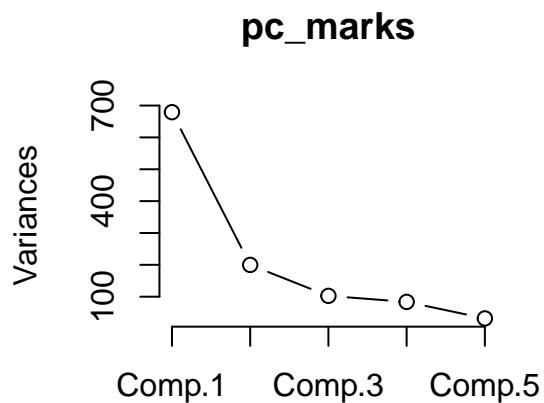
## Importance of components:
##                               Comp.1    Comp.2    Comp.3    Comp.4    Comp.5
## Standard deviation      26.061142 14.1355705 10.12760414 9.14706148 5.63807655
## Proportion of Variance 0.619115  0.1821424  0.09349705 0.07626893 0.02897653
## Cumulative Proportion   0.619115  0.8012575  0.89475453 0.97102347 1.00000000

loadings(pc_marks)

## 
## Loadings:
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## mechanics  0.505  0.749  0.300  0.296
## vectors    0.368  0.207 -0.416 -0.783  0.189
## algebra    0.346          -0.145          -0.924
## analysis   0.451 -0.301 -0.597  0.518  0.286
## statistics 0.535 -0.548  0.600 -0.176  0.151
##
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings 1.0    1.0    1.0    1.0    1.0
## Proportion Var 0.2    0.2    0.2    0.2    0.2
## Cumulative Var 0.2    0.4    0.6    0.8    1.0

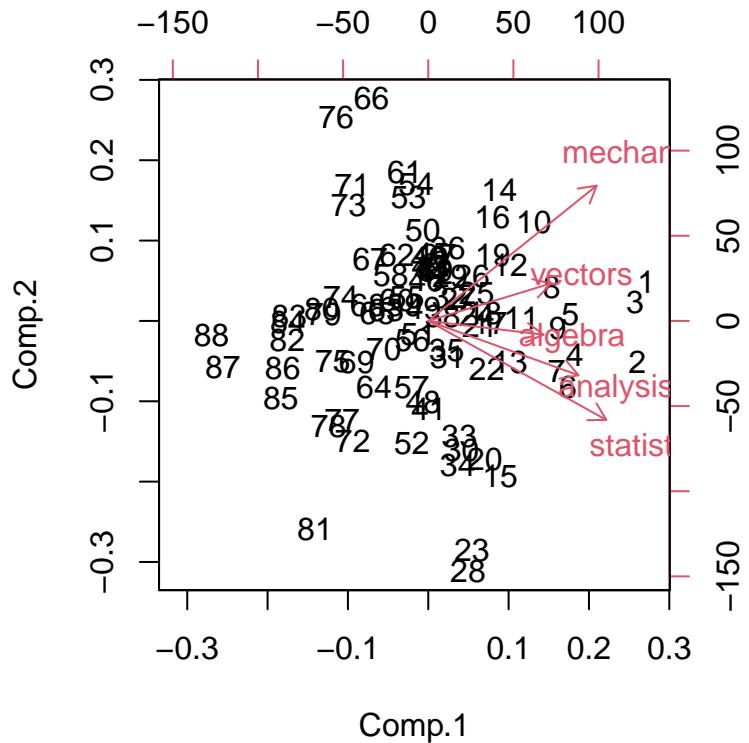
plot(pc_marks, type = "lines")

```



Y graficamos:

```
biplot(pc_marks)
```



Los cálculos de un análisis de componentes principales involucran la matriz de covarianzas empírica  $G$  (estimaciones *plug-in*)

$$G_{jk} = \frac{1}{88} \sum_{i=1}^8 8(x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

para  $j, k = 1, 2, 3, 4, 5$ , y donde  $\bar{x}_j = \sum_{i=1}^8 x_{ij}/88$  (la media de la i-ésima columna).

```
G <- cov(marks) * 87 / 88
G
```

```
##               mechanics   vectors   algebra analysis statistics
## mechanics    302.2934 125.77686 100.42510 105.06508 116.07076
## vectors      125.7769 170.87810  84.18957  93.59711  97.88688
## algebra     100.4251  84.18957 111.60318 110.83936 120.48567
## analysis     105.0651  93.59711 110.83936 217.87603 153.76808
## statistics   116.0708  97.88688 120.48567 153.76808 294.37177
```

Los *pesos* y las *componentes principales* no son mas que los eigenvalores y eigenvectores de la matriz de covarianzas  $G$ , estos se calculan a través de una serie de manipulaciones algebraicas que requieren cálculos del orden de  $p^3$  (cuando  $G$  es una matriz de tamaño  $p \times p$ ).

```
eigen_G <- eigen(G)
lambda <- eigen_G$values
v <- eigen_G$`vectors`
lambda
```

```

## [1] 679.18311 199.81435 102.56837 83.66873 31.78791

v

## [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] -0.5054457  0.74874751  0.2997888  0.296184264 -0.07939388
## [2,] -0.3683486  0.20740314 -0.4155900 -0.782888173 -0.18887639
## [3,] -0.3456612 -0.07590813 -0.1453182 -0.003236339  0.92392015
## [4,] -0.4511226 -0.30088849 -0.5966265  0.518139724 -0.28552169
## [5,] -0.5346501 -0.54778205  0.6002758 -0.175732020 -0.15123239

```

1. Proponemos el siguiente modelo simple para puntajes correlacionados:

$$\mathbf{x}_i = Q_i \mathbf{v}$$

donde  $\mathbf{x}_i$  es la tupla de calificaciones del  $i$ -ésimo estudiante,  $Q_i$  es un número que representa la habilidad del estudiante y  $\mathbf{v}$  es un vector fijo con 5 números que aplica a todos los estudiantes. Si este modelo simple fuera cierto, entonces únicamente el  $\hat{\lambda}_1$  sería positivo y  $\mathbf{v} = \hat{\mathbf{v}}_1$ . Sea

$$\hat{\theta} = \sum_{i=1}^5 \hat{\lambda}_i$$

el modelo propuesto es equivalente a  $\hat{\theta} = 1$ , incluso si el modelo es correcto, no esperamos que  $\hat{\theta}$  sea exactamente uno pues hay ruido en los datos.

```

theta_hat <- lambda[1]/sum(lambda)
theta_hat

```

```

## [1] 0.619115

```

El valor de  $\hat{\theta}$  mide el porcentaje de la varianza explicada en la primer componente principal, ¿qué tan preciso es  $\hat{\theta}$ ? La complejidad matemática en el cálculo de  $\hat{\theta}$  es irrelevante siempre y cuando podamos calcular  $\hat{\theta}^*$  para una muestra bootstrap, en esta caso una muestra bootstrap es una base de datos de  $88 \times 5 \mathbf{X}^*$ , donde las filas  $\mathbf{x}_i^*$  de  $\mathbf{X}^*$  son una muestra aleatoria de tamaño 88 de la verdadera matriz de datos.

- Utiliza bootstrap para calcular el error estándar de  $\hat{\theta}$ .
- Grafica la distribución bootstrap.

```

p_boot <- function(){
  muestra_boot <- sample_n(marks, size = 88, replace = TRUE)
  G <- cov(muestra_boot) * 87 / 88
  eigen_G <- eigen(G)
  theta_hat <- eigen_G$values[1] / sum(eigen_G$values)
}

n <- 500

library(plyr)

```

```

## -----

```

```

## You have loaded plyr after dplyr - this is likely to cause problems.
## If you need functions from both plyr and dplyr, please load plyr first, then dplyr:
## library(plyr); library(dplyr)

## -----
## 
## Attaching package: 'plyr'

## The following objects are masked from 'package:Hmisc':
## 
##     is.discrete, summarize

## The following objects are masked from 'package:srvyr':
## 
##     mutate, rename, summarise, summarize

## The following objects are masked from 'package:dplyr':
## 
##     arrange, count, desc, failwith, id, mutate, rename, summarise,
##     summarize

thetas_boot <- rdply(n, p_boot)

ggplot(thetas_boot, aes(x = V1)) +
  geom_histogram(aes(y = ..density..), color = "white", fill = "gray", binwidth = 0.015) +
  geom_density(color = "blue") +
  geom_vline(aes(xintercept = mean(V1), color = "red"))

```

